

Multiple lineare Regression im Maschinellen Lernen für Predictive Analytics

Alexander Dentler

Wer trägt zum Teamerfolg bei — und wie messen wir das rigoros?

Lehrer / Professor • HR-Manager / Teamleiter • Sportscout

Am Ende dieser Lehrveranstaltung können Sie:

- 1 **Erklären**, warum einfache Statistiken (Tore, Assists) den **individuellen Spielerbeitrag** nicht messen.
- 2 **Beschreiben**, wie lineare Regression sportliche Beiträge (Contributions) schätzt — und multiple Regression dabei für alle anderen Faktoren (Mitspieler und Gegner) kontrolliert.
- 3 **Beurteilen**, wann OLS versagt und warum Lasso-Regularisierung notwendig wird.
- 4 **Übertragen**: dieselbe Logik auf BWL-Kontexte (Marketing-Attribution, Personalproduktivität).

Tore zählen reicht nicht — warum nicht?

Was wir wirklich wissen wollen:

Wie viel **Tordifferenz** erzeugt Spieler i —
verglichen mit einem **Durchschnittsspieler** —

wenn er auf dem Platz steht?

... und das **kontrolliert** für alle
anderen Spieler, die gleichzeitig spielen.

Zielgröße: Tordifferenz $\Rightarrow$ Erfolg

Werkzeug: Multiple lineare Regression

Was wir heute messen:


- 1 **Tore & Assists** — Fokus auf Offensivspieler
- 2 **Granulare Daten** (Laufstrecke, Pässe, Ballkontakte):
 $\Rightarrow$ messen **Aktivität**, nicht **Wirkung**
- 3 **Videoanalyse** (Verhaltensbeobachtung):
 $\Rightarrow$ schwer quantifizierbarer **Eindruck**,
 $\Rightarrow$ teuer & zeitaufwendig

Wie wir aufmerksam werden:

- **Scouting** (Netzwerke):
 - subjektiv und lückenhaft
 - Dann folgt: medizinische, psychologische, rechtliche Due Diligence

Schritt 1: Die einfache lineare Regression

Umsatz (Tsd. €)



Grundbegriffe:

1 Modell vs. Beobachtung:

Vorhersage: $\hat{y}_i = \alpha + \beta \cdot x_i$

Beobachtung: $y_i = \underbrace{\alpha + \beta \cdot x_i}_{\hat{y}_i} + e_i$

2 Residuum = Abstand Beobachtung $\leftrightarrow$

Vorhersage:

$$e_i = y_i - \hat{y}_i$$


3 Zielfunktion:

$$\text{Minimiere } \sum_{i=1}^n e_i^2$$

β : Um wie viel steigt $\hat{y}$,
wenn x um eine Einheit steigt?

Schritt 1: Die einfache lineare Regression

Umsatz (Tsd. €)



Grundbegriffe:

1 Modell vs. Beobachtung:

Vorhersage: $\hat{y}_i = \alpha + \beta \cdot x_i$

Beobachtung: $y_i = \underbrace{\alpha + \beta \cdot x_i}_{\hat{y}_i} + e_i$

2 Residuum = Abstand Beobachtung $\leftrightarrow$

Vorhersage:

$$e_i = y_i - \hat{y}_i$$

3 Zielfunktion:

$$\text{Minimiere } \sum_{i=1}^n e_i^2$$

β : Um wie viel steigt $\hat{y}$,
wenn x um eine Einheit steigt?

Was bedeutet der Koeffizient β ?

KOEFFIZIENT β

β misst den **bedingten Zusammenhang** von x und y :

Wenn x um 1 steigt — bei *sonst gleichen Bedingungen* — steigt $\hat{y}$ im Durchschnitt um β .

- **Einheit:** immer relativ zu den Einheiten von x und y
- **Vorzeichen:** positiv = gleichläufig, negativ = gegenläufig
- **“Bedingt”:** hält alles konstant, was *nicht* in x steckt

Gefahr: Confounding

Ein Stürmer erzielt viele Tore, weil das Team gut ist
—

oder weil er selbst gut ist?

Wir können es **nicht trennen**, solange wir nur *einen* Erklärer haben.

⇒ Multiple Regression mit **vielen** Erklärern

Gedankenexperiment: zwei Teams, eine Auswechslung

- **1. Halbzeit:**

A_1 und A_2 spielen für Team A

B_1 und B_2 spielen für Team B

Ergebnis: **0 : 0**

- **Halbzeitpause:** A_2 wird durch A_3 ersetzt

- **2. Halbzeit:** Ergebnis: **2 : 0**

	Team A			Team B		Tordiff.
	A_1	A_2	A_3	B_1	B_2	
1. HZ	+1	+1	0	-1	-1	0
2. HZ	+1	0	+1	-1	-1	+2

Viele Beobachtungen $\Rightarrow$ stabile Schätzung

Schlussfolgerung

Tordifferenz (y): $0 \Rightarrow 2$ pro Halbzeit —
auf 90 Min. hochgerechnet: $\Delta = +4$.

Attribuierbar allein auf $A_2 \rightarrow A_3$ —
alle anderen Spieler blieben gleich.

Von vier Spielern zu 494

	A ₁	A ₂	...	A ₁₁	A ₁₂	...	B ₁	B ₂	...	B ₁₁	...	Tordiff.	Zeit
Seg. 1	+1	+1	...	+1	0	...	-1	-1	...	-1	...	0	57'
Seg. 2	+1	0	...	+1	+1	...	-1	-1	...	-1	...	+2	23'
⋮	⋮	⋮		⋮	⋮		⋮	⋮		⋮		⋮	⋮
<i>Seg. 1206</i>	0	-1	...	-1	-1	...	+1	+1	...	+1	...	+1	42'
⋮	⋮	⋮		⋮	⋮		⋮	⋮		⋮		⋮	⋮

Verallgemeinerung:

- **+1** = Heimteam auf dem Platz
- **-1** = Auswärtsteam auf dem Platz
- **0** = nicht auf dem Platz
- w_i = Segmentdauer (Gewicht)

Bundesliga 2025/26:

- 306 Spiele $\Rightarrow$ 2008 Segmente (Zeilen)
- 494 Spieler (Spalten)
- y : Tordifferenz pro Segment

$$\hat{y} = \sum_{i=1}^{494} \beta_i \cdot x_i$$

$$\min_{\beta} \sum_{j=1}^{2008} w_j e_j^2$$

Was bedeutet β_i für einen Spieler?

$\hat{\beta}_i$ = erwarteter Beitrag zur Tordifferenz **pro 90 Minuten**,
den Spieler i auf dem Platz liefert —
relativ zum Durchschnittsspieler der Liga,
bei gleichzeitiger Kontrolle aller anderen Spieler auf dem Platz.

$$\beta = +2,0$$

Tordiff. $\approx +2$ pro 90 Min.
über Ligadurchschnitt

$$\beta = 0,0$$

Genau Ligadurchschnitt

$$\beta = -1,5$$

Tordiff. $\approx -1,5$ pro 90 Min.
unter Ligadurchschnitt

Ergebnis I: Was sagt OLS?

#	Spieler	Pos	Verein	FTE	β_{OLS}	Tore	Assists
1	Manuel Neuer	G	Bayern München	20,7	9,77	0	0
2	Jonas Urbig	G	Bayern München	12,3	9,19	0	0
3	S. Ulreich	G	Bayern München	1,0	8,29	0	0
4	Kaishu Sano	M	FSV Mainz 05	34,0	7,14	1	3
5	Nikola Vasilj	G	FC St. Pauli	34,0	6,72	0	0
6	Kamil Grabara	G	VfL Wolfsburg	34,0	6,48	0	0
7	Patrick Mainka	D	1. FC Heidenheim	34,0	2,73	2	2
8	K. Hein	G	Werder Bremen	2,0	2,29	0	0
9	Mio Backhaus	G	Werder Bremen	32,0	1,96	0	0
10	L. Paqarada	D	1. FC Heidenheim	0,1	1,95	0	0

Was fällt auf?

Ergebnis I: Was sagt OLS?

#	Spieler	Pos	Verein	FTE	β_{OLS}	Tore	Assists
1	Manuel Neuer	G	Bayern München	20,7	9,77	0	0
2	Jonas Urbig	G	Bayern München	12,3	9,19	0	0
3	S. Ulreich	G	Bayern München	1,0	8,29	0	0
4	Kaishu Sano	M	FSV Mainz 05	34,0	7,14	1	3
5	Nikola Vasilj	G	FC St. Pauli	34,0	6,72	0	0
6	Kamil Grabara	G	VfL Wolfsburg	34,0	6,48	0	0
7	Patrick Mainka	D	1. FC Heidenheim	34,0	2,73	2	2
8	K. Hein	G	Werder Bremen	2,0	2,29	0	0
9	Mio Backhaus	G	Werder Bremen	32,0	1,96	0	0
10	L. Paqarada	D	1. FC Heidenheim	0,1	1,95	0	0

■ Torwart (G) ■ FTE = 34 (volle Saison)

Debugging mit KI: Was sagt Claude?

OLS-Regression: Tordifferenz auf 494 Spielerdummies (+1 Heim, -1 Auswärts, 0 abwesend), 2008 Bundesliga-Segmente 2025/26 — ein Segment ist ein ununterbrochener Spielabschnitt ohne Auswechslung oder rote Karte. Drei Bayern-Torhüter auf Rang 1–3 mit $\hat{\beta} \approx 9$, null Tore, null Assists. Was ist die methodische Ursache?

Near-Singularity / Multikollinearität.

Spieler mit FTE = 34 (volle Saison) erzeugen eine Spaltenspalte, die identisch mit der Teamindikatorfunktion ist — OLS kann individuellen Beitrag nicht von der Teamstärke trennen. Der Koeffizient absorbiert den Teameffekt wie eine Konstante.

Empfehlung: Lasso oder Ridge.

So arbeitet man mit Daten: Modell bauen → Diagnose → Revision.

Manche Spieler

- spielen **fast immer**
- treten **fast immer gemeinsam** auf
- spielen **sehr wenig**

⇒ OLS braucht **linear unabhängige** Spalten

Near-Singularity / Rank-Condition-Verletzung:

Exakt gleiche Spalten: OLS nicht eindeutig — unendlich viele β -Kombinationen möglich.

Nahezu gleiche Spalten: OLS instabil — kleine Datenänderung, große β -Sprünge.

Die Lösung: Regularisierung

- **Lasso:** $\min_{\beta} \sum_i w_i e_i^2 + \gamma \sum_j |\beta_j|$
 - Wählt wenige aus und setzt andere auf null.
- **Ridge:** $\min_{\beta} \sum_i w_i e_i^2 + \gamma \sum_j \beta_j^2$
 - Verteilt den Effekt oft auf mehrere ähnliche Variablen.
- γ -Wahl:
 - Stärke der Regularisierung
 - automatisch via AIC
 - Bundesliga: $\gamma = 0,000141$ (AIC-gewählt)

$$e_i = y_i - \hat{y}_i \quad (\text{Residuum})$$

Ergebnis II: Was sagt Lasso? ($\gamma = 0,000141$, AIC-gewählt)

#	Spieler	Pos	Verein	FTE	β_{Lasso}	β_{OLS}	Tore	Assists
1	Kaishu Sano	M	FSV Mainz 05	34,0	2,29	7,14	1	3
2	J. Burkardt	F	Eintracht Frankfurt	14,9	1,34	1,44	13	1
3	N. Nartey	F	VfB Stuttgart	13,9	1,08	0,98	4	3
4	David Raum	D	RB Leipzig	28,5	1,05	1,59	3	7
5	A. Ouédraogo	M	RB Leipzig	10,5	1,05	1,04	4	3
6	J. Adamu	F	SC Freiburg	5,1	1,04	1,65	1	1
7	A. Hajdari	D	1899 Hoffenheim	27,1	1,03	1,75	1	2
8	I. Matanović	F	SC Freiburg	17,6	1,00	1,62	11	2
9	Nico Elvedi	D	Borussia M'bach	33,0	0,98	1,43	0	2
10	K. Grabara	G	VfL Wolfsburg	34,0	0,95	6,48	0	0

Rang 1: Sano (M, 1 Tor, 3 Assists). **Grabara:** OLS 6,48 $\rightarrow$ Lasso 0,95 — Regularisierung wirkt.

Drei Grenzen:

- 1 **Multikollinearität** bleibt ein Problem bei Teams, die selten rotieren
- 2 **Standardfehler** bei geringer Einsatzvariation sehr groß:
Neuer (OLS): $\hat{\beta} = 9,77$, $SE = 4,47$ — größer als der Koeffizient
- 3 **Keine externe Validierung:** kein Goldstandard;
indirekte Konsistenz-Checks (Stürmer- $\beta \leftrightarrow$ Tore)

Praxisfrage: Wie verkauft man $\beta = 2,29$
einem erfahrenen Scout bei
1. FC Magdeburg oder Eintracht Braunschweig?

Transfer in die BWL:

- **Immobilienpreise:** Was trägt Balkon, Lage, Baujahr je zum Preis bei, wenn alles korreliert?
- **Credit Scoring:** Einkommen, Schuldenquote, Beschäftigungsdauer — was erklärt Ausfallrisiko?
- **Filialperformance:** Standort, Fläche, Personal oder Promotion — was treibt Umsatz?
- **Personalproduktivität:** Training, Teamgröße, Führungsstil — wer trägt was zur Leistung bei?
- **Lieferkette:** Defektrate, Lieferzeit oder Preis — was treibt Ausfallwahrscheinlichkeit?

Identische Modellstruktur —
nur anderer Anwendungskontext.

Lineare Regression als
universelles Mess-Instrument.

Aus aktuellem Anlass: DFB-WM-Kader 2026

Spieler	Verein	FTE	β	T	A
Torwart					
Manuel Neuer	Bayern	20,7	+0,62	0	0
Alexander Nübel	Stuttgart	34,0	0,00	0	1
Oliver Baumann	Hoffenheim	34,0	-0,47	0	0
Abwehr					
David Raum	Leipzig	28,5	+1,05	3	7
Jonathan Tah	Bayern	22,5	+0,16	2	2
Antonio Rüdiger	Real Madrid (LL)	12,1	+0,08	1	0
Malick Thiaw	Newcastle (PL)	33,1	+0,04	4	0
Nathaniel Brown	Frankfurt	29,5	-0,11	4	4
N. Schlotterbeck	Dortmund	28,0	-0,29	5	1
Waldemar Anton	Dortmund	32,0	-0,52	2	0
Sturm					
Deniz Undav	Stuttgart	24,9	+0,48	19	6
Maximilian Beier	Dortmund	22,7	+0,40	9	6
Nick Woltemade	Newcastle (PL)	20,9	+0,37	8	3
Kai Havertz	Arsenal (PL)	6,5	+0,11	2	3

Spieler	Verein	FTE	β	T	A
Mittelfeld					
Jamal Musiala	Bayern	7,5	+0,87	3	4
Angelo Stiller	Stuttgart	30,6	+0,52	2	5
Lennart Karl	Bayern	14,1	+0,35	5	5
Leroy Sané	Galatasaray (SL)	20,2	+0,18	6	5
Florian Wirtz	Liverpool (PL)	26,0	+0,11	5	3
Felix Nmecha	Dortmund	24,1	0,00	3	4
Jamie Leweling	Stuttgart	26,3	0,00	7	10
Nadiem Amiri	Mainz 05	23,2	0,00	12	2
Pascal Groß	Dortmund	6,7	-0,24	0	1
Leon Goretzka	Bayern	21,9	-0,35	5	3
Joshua Kimmich	Bayern	25,3	-0,46	2	9
A. Pavlović	Bayern	16,2	-0,81	3	1

BL=Bundesliga, PL=Premier League, LL=La Liga, SL=Süper Lig | Rot: FTE<10 oder $\beta < -0,5$

Nicht nominiert — aber Modell-positiv (Top-5-Ligen)

#	Spieler	Pos	Verein	FTE	β_{Lasso}	Tore	Assists
1	M. Arnold	M	VfL Wolfsburg	14,0	2,17	1	3
2	Chabot	D	VfB Stuttgart	11,2	0,70	0	0
3	A. Stach	M	Leeds United (PL)	15,2	0,59	3	2
4	Ansah	F	1. FC Union	12,0	0,56	5	2
5	K. Dorsch	M	1. FC Heidenheim	10,1	0,45	0	0
6	Fellhauer	M	FC Augsburg	13,2	0,39	1	1
7	Schöppner	M	1. FC Heidenheim	11,6	0,38	1	0
8	Zehnter	D	VfL Wolfsburg	11,0	0,35	2	0
9	C. Kübler	D	SC Freiburg	10,1	0,22	2	1
10	Wahl	D	FC St. Pauli	13,5	0,22	1	0
11	Toure	M	AC Pisa (IT)	10,2	0,18	1	0
12	M. Ginter	D	SC Freiburg	15,0	0,16	0	2

Caveat: Koeffizienten sind ligarelativ — $\beta = 2,17$ in der Bundesliga ist *nicht* direkt vergleichbar mit $\beta = 0,59$ in der Premier League.

Zwei Dinge zum Mitnehmen

1. Wer die Datenstruktur klug aufbaut (Segmente!), öffnet Fragen, die mit Rohdaten nicht beantwortbar wären.
2. Ein Modell, das überrascht, ist wertvoller als eines, das nur Bekanntes bestätigt —
*vorausgesetzt, man versteht warum
und man es vertrauenswürdig kommunizieren kann.*

Bundesliga 2025/26 · 494 Spieler · 2 008 Segmente · $R^2 = 0,633$ · Lasso $\gamma = 0,000141$
· *Showcase-Paket und Methodik auf Anfrage verfügbar.*

Additional Remark A: Was bedeutet der Intercept β_0 ?

Technische Bedeutung:

- β_0 = erwartete Tordifferenz, wenn **kein Spieler** auf dem Platz steht
- Das ist strukturell ≈ 0
- Im Fußball-Modell: **keine substantielle Bedeutung**

Wann ist der Intercept wichtig?

- Bei $\hat{y} = \alpha + \beta \cdot x_{\text{Werbung}}$:
 α = Grundumsatz *ohne* Werbung
- Faustregel: Intercept ist relevant, wenn $x = 0$ eine sinnvolle Beobachtung ist oder Beobachtungen weit weg sind
- Im Spieler-Modell: $x = 0$ für alle 494 Spieler ist keine sinnvolle Spielsituation

SEGMENT

Ein ununterbrochener Spielabschnitt, in dem **alle 22 Spieler auf dem Platz konstant** bleiben.

Wann entsteht ein neues Segment?

- Einwechslung (Auswechslung eines Spielers)
- Rote Karte (Spieler verlässt ohne Ersatz)


Bundesliga 2025/26:

- $306 \text{ Spiele} \times \approx 6,6 \text{ Segmente/Spiel} \approx 2\,008 \text{ Segmente}$
- Gewichtung: Segment-Dauer in Minuten
- Ein 60-Min-Segment zählt 3-fach gegenüber einem 20-Min-Segment


Warum nicht einfach pro Spiel?

Ohne Segmentierung kann man Auswechslungs-Effekte nicht separieren — der Mehrwert des Modells entfällt.


Additional Remark C: OLS vs. Lasso — Streudiagramm



OLS β -Verteilung:



Lasso β -Verteilung:



Punkte **weit unter der Diagonalen**: Lasso schrumpft stark (schlecht identifizierte Koeffizienten).
Rot = Torhüter (Bayern-GKs weit links unten). Grün = Feldspieler, Blau = Mittelfeld, Orange = Sturm.

Ökonometrie Erklärend	Machine Learning Prädiktiv
Warum ist das Ergebnis so? Kausale Interpretation	Was wird das Ergebnis sein? Genauigkeit der Vorhersage

Unser Modell kann beides:

- **Prädiktiv:** Aufstellung $\rightarrow$ vorhergesagte Tordifferenz
 $R^2 = 0,633$
- **Interpretierbar:** $\hat{\beta}_i$ ist direkt lesbar als Spielerbeitrag in Tordifferenz/90 Min

BWL-Analogie: Marketing-Mix-Modell

TV- und Online-Kampagnen schalten immer gleichzeitig $\rightarrow$ OLS kann nicht attribuieren. Lasso/Ridge können es.